DUDUDA / PROJECT OVERVIEW

嘟嘟哒　作品简介

群聊原生社交智能体

第 4 项提交材料 | 2026 年 9 月 6 日 | github.com/ly382965/dududa

1 作品背景与解决的问题

嘟嘟哒面向 QQ 群中的持续交流，将自然语言理解、群聊参与、校园查询和人格表达组织成一套智能体系统。它以“生活在 QQ 群里的 AI 群友”为产品定位，首批服务于校园生活、教学支持和群体协作。

群聊中的请求经常分散在多人发言里：有人提出问题，有人补充条件，有人临时更正；课程、活动、通知和教务资料又来自不同网站。用户需要一个能够理解当前讨论、在适当时机参与、查询资料并说明来源的入口。管理员则需要按群控制参与频率和服务范围，查看回答所使用的模型、工具及运行结果。

作品围绕三个实际问题展开：**从连续讨论中理解需求；将需求落到可用的校园服务；让群聊参与有节奏、可配置、可解释**。明确提及 Bot 可发起任务；在目标群开启自动参与后，普通讨论也能形成回应机会。

2 核心功能

功能	具体能力
群聊理解与参与	读取同群近期上下文，处理引用、追问与更正；按群配置参与概率、冷却和每小时上限。
评课与教学支持	查询课程、教师、评论与统计；区分同名条目，按讨论需求组织有来源的建议。
活动与教务	搜索第二课堂活动，读取详情和类别；查询学期、全校开课、考试与教学日历。
方案、通知与出行	查询不同年级的培养方案资料、校园通知及截止日期；按路线、日期和时段查校车。
自适应插件选择	在管理员已授权的只读插件集合中，根据多人连续讨论和当前请求选择、启用匹配的查询能力。
人格与扩展交互	独立 Persona 资产与表达规则；表情合成、复读和曲目信息等扩展由相应插件提供。
管理与调试	Web 展示 Agent 对话、实际模型、能力与耗时，支持群配置、三档 Key 池和 MCP 连接检查。

培养方案使用有版本的非官方研究快照，校车使用静态时刻表；二课认证在部署端配置。个人成绩、代报名、个人学时查询不属于本次校园智能体范围。

3 技术架构与实现方法

系统以 Python Runtime 为核心，通过 AstrBot/NapCat 接入 QQ，通过 MCP 与本地 Provider 连接校园资料，使用 Vue 3/Node.js 提供管理控制台。QQ 与 Web 预览复用同一运行核心。

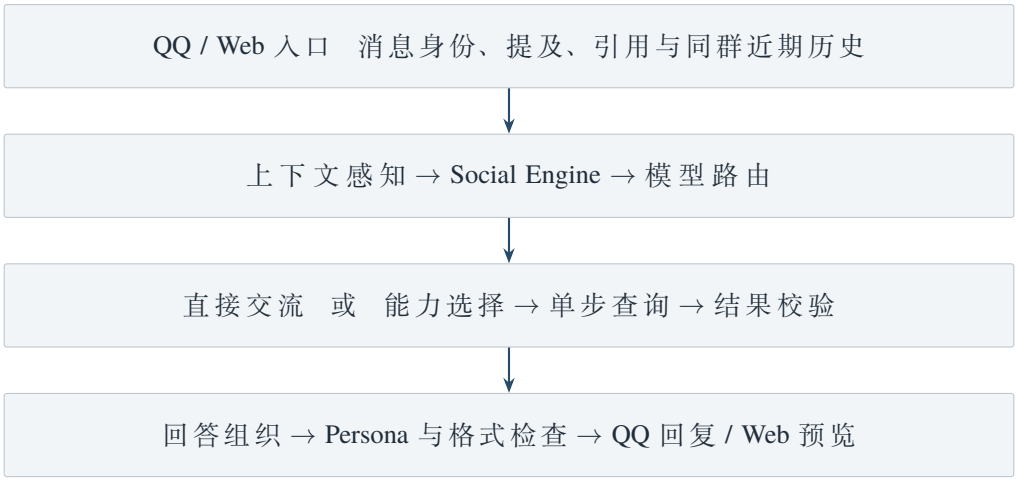


图 1 当前主要运行流程。长期 Memory 与多步 Skill 另处于接入或后续建设阶段。

规则与模型协同。规则识别明确来源、平台信号和输入约束，模型提取意图与实体。结构化语义经过校验，再由确定性策略选择回应、查询、澄清或静默；身份、权限和输出目标由程序维护。

业务能力统一。课程、活动、通知等服务各自声明输入输出与 Provider，Planner 把自然语言条件绑定到有界业务查询。当前采用单步计划，MCP worker 使用独立解释器解决宿主与客户端的依赖版本差异。

计算与表达分开。模型档位、推理强度和正文篇幅分别设置。人格影响语气与信息呈现，不能改变工具事实、来源和用户指定的精确格式。

4 WebUI 工作台设计

WebUI 将真实 QQ 会话与智能体管理放在同一工作区：桌面端并列显示账号栏、会话列表、聊天窗和可折叠的 Agent 面板；手机端通过单页切换保留当前会话。界面提供浅色和深色主题，以明确的文字和状态色区分 QQ 在线、Runtime 可用及配置生效情况。

页面区域	设计与使用方式
消息工作区	查看同群讨论、读取历史和搜索已缓存消息；账号与会话始终对应当前操作。
Agent 三个页签	“对话”输入问题和阅读回答；“运行”检查实际模型、工具、上下文与耗时；“配置”维护群行为与插件范围。
模型与工具管理	管理三档 Key 池、MCP 连接和插件；分别显示保存结果及应用到 Runtime 的状态。
连接与异常反馈	首屏先显示工作区，后台刷新目录；错误指出历史读取、账号登录或 Runtime 调用等具体环节，并提供重试。

浏览器以同源 HTTP/SSE 连接 Node.js 网关；网关负责 QQ 同步，并从服务端取得近期历史，交给 AstrBot 中的既有 Runtime 生成预览。预览可使用校园工具，结果留在 Web 中供管理员检查。该设计让管理员沿“阅读讨论—设置服务—检查回答”完成连续操作。配套《设计文档》设有独立的“WebUI 设计”一章，详述布局、数据流、交互及实现依据。

5 创新点

嘟嘟哒以**自适应**为核心：围绕当前群聊情境，分别调整使用的插件、计算路由和参与方式，并通过 WebUI 展示选择过程、支持人工配置。

1. **自适应插件选择**。结合讨论主题、多人参与、需求持续性与当前请求，在管理员授权的服务集合中选择并启用匹配插件。例如，选课讨论形成明确需求后启用评课查询，记录启用原因，将自然讨论连接到具体校园服务。
2. **任务驱动的自适应路由**。根据意图、复杂度信号、置信度、可用模型和预算选择计算档位，并独立配置推理强度与回答篇幅。简单交流与复杂分析可采用不同路由，实际选择随本轮任务变化，并保留选择依据。
3. **自适应群聊参与与表达**。结合提及、追问、持续讨论和群策略选择回复、查询、澄清或静默；再按任务组织回答篇幅与人格表达，使参与方式适应当前情境，同时遵守配置的冷却和频率限制。
4. **WebUI 工作台设计**。将真实 QQ 会话与 Agent 对话、运行、配置整合为连续操作；管理员按群设置偏好、允许范围与锁定项，观察实际模型、插件、上下文和耗时，形成“配置—预览—观察—调整”的自适应管理流程。

这些创新集中在可解释、可配置的情境适应机制：当前以语义感知、规则与策略组合实现，在线学习另作为后续研究方向。

6 使用的模型及 API 调用方式

本次演示使用 DeepSeek，常规配置如下。界面和内部档位均为程序别名，实际模型以请求中的 model 字段为准。

表 1 模型配置

界面档位	内部别名	实际模型 ID	常规推理强度
Luna 快速	haiku	`deepseek-v4-flash`	low
Terra 标准	sonnet	`deepseek-v4-flash`	high
Sol 深度	opus	`deepseek-v4-pro`	max

服务地址为 `https://api.deepseek.com`，协议为 **OpenAI 兼容 Chat Completions**。调用链为 Runtime → AstrBotModelProviderAdapter → AstrBot Provider.text_chat → DeepSeek HTTP API。后端传入提示词、模型、输出额度、thinking 与 reasoning_effort，接收回答正文和 token 用量。

2026 年 9 月 6 日录制查询配置保留快速档轻量推理，标准档和深度档使用 `thinking:disabled`，直接组织工具资料。以下为标准档录制模式的等价请求示意：

```
POST https://api.deepseek.com/chat/completions
Authorization: Bearer <DEPLOYMENT_API_KEY>
Content-Type: application/json
{
  "model": "deepseek-v4-flash",
  "messages": [
    {"role": "system", "content": "<task instructions>"},
    {"role": "user", "content": "<question and tool evidence>"}
  ],
  "thinking": {"type": "disabled"},
  "max_tokens": 8192
}
```

常规推理模式改为 thinking enabled，并设置 low/high/max 等 reasoning_effort。真实 API Key 在部署端管理。校园工具由程序执行后将结果交给模型，当前主链不依赖模型原生 Function Calling 自主执行工具。

字段依据：DeepSeek 官方 Thinking Mode 文档，2026 年 9 月 6 日核对；项目实际参数以模型适配器及运行配置为准。

7 实际使用示例

选课讨论：群内连续提出讲解风格、证明训练和课业负担等需求；条件满足且已有授权后，系统启用评课能力，查询课程与教师评论，按不同需求组织建议并附链接。

校园查询：用户询问二课英语角、某学期开课记录、培养方案学分或校车时刻，系统定位业务、提取条件并返回资料。对不存在、未取得或版本不明确的信息，应说明范围或请求澄清。

8 已有成果与验证

当前成果包括 QQ 接入、近期上下文、Social Engine、按群自动参与、授权自适应启用、六类校园查询、三档模型配置、独立 Persona 资产和 Web 控制台。验证材料按执行层级分别统计：

验证类型	已存结果与解释
100 条离线流程	94 条 Runtime 响应，6 条入口规则处理；187 次脚本模型调用、53 次 MCP fixture 调用、11 次本地能力调用。预期检查无不匹配，真实 QQ 发送为 0。本次报告编制已复跑。
26 项原子 MCP 查询	选定案例 26/26 通过；包括真实校园服务与可选服务的查询，证明这些调用可用。
5 项真实模型问答	Flash 标准档预览 5/5 通过对应检查；涵盖开课、培养方案、通知、校车、二课，单次总耗时 10.92—29.07 秒。
四人讨论排练	20 条模拟发言，前 19 条评课关闭，第 20 条启用并查询；原生排练记录 1 次输出调用与完成处置。
广覆盖真实预览	较早 93 次真实模型预览审查为 60 通过、25 部分、8 失败；仍保留问题清单，未用后续少量样本代替全量复测。

离线流程验证不等于真实模型准确率，选定演示样本也不构成总体性能或效果统计。模拟群成员输入与真实 QQ 用户完整发言分别说明；具体证据、复现命令和限制见配套《设计文档》的“验证结果与完成度”一章。

9 当前边界与后续建设

Memory v2 已实现作用域检索、中文 BM25、写入筛选和生命周期组件，主动调度、摘要与 Bandit 也有独立或离线成果。**长期记忆尚未接入正式聊天，通用多步 Skill、多 OC 切换、群友印象和在线学习仍需建设**。

近期优化聚焦查询前澄清、来源完整性、近期摘要的时间与发言归属，以及查询耗时和参与误触发。后续以实际群聊任务评估长期记忆和组合能力的收益，逐步扩展到更多校园及群体协作场景。

10 交付与技术资料

作品提供可部署源码、依赖锁文件、核心 wheel、Web 构建产物、Docker Compose 和测试入口。部署者配置模型服务、必要校园认证与 QQ 账号后可连接运行，也可先使用无需模型 Key 的离线流程。

配套设计文档整合本地技术资料，附来源索引和 LaTeX 源码。两份报告实际采用 ElegantPaper 中文模板，原模板许可证随源码提供。

项目入口： github.com/ly382965/dududa

材料依据： 主仓源码与各服务 README、录制验证记录、群聊 100 题结果、Memory/Persona 设计及离线评测数据卡；详细路径见配套设计文档与本地文档汇总。